

# Güneş Paneli Görüntü Analizi

## (Solar Panel Image Analysis)



**Lilas Muhammed**  
Bilgisayar Mühendisliği  
İstanbul Topkapı  
Üniversitesi  
İstanbul, Türkiye  
[lilasmuhammed@stu.topkapi.edu.tr](mailto:lilasmuhammed@stu.topkapi.edu.tr)



**Fadila Hachach**  
Bilgisayar Mühendisliği  
İstanbul Topkapı  
Üniversitesi  
İstanbul, Türkiye  
[fadilahachach@stu.topkapi.edu.tr](mailto:fadilahachach@stu.topkapi.edu.tr)



**Musaab Al Taweel**  
Bilgisayar Mühendisliği  
İstanbul Topkapı  
Üniversitesi  
İstanbul, Türkiye  
[musaabaltaweel@stu.topkapi.edu.tr](mailto:musaabaltaweel@stu.topkapi.edu.tr)

### I. GİRİŞ

**Özet—** Bu proje, güneş panellerindeki toz, fiziksel ve elektriksel hasar gibi sorunları tespit etmek için bir görüntü sınıflandırma modeli geliştirmeyi hedeflemektedir. Kaggle'dan alınan, farklı koşullarda çekilmiş 875 görüntüden oluşan veri seti şu kategorilere ayrılmıştır: Kuş Dışkısı, Temiz, Tozlu, Elektriksel Hasar, Fiziksel Hasar, ve Karla Kaplı. Model olarak InceptionV3 seçilmiş ve %96.72 doğruluk oranıyla başarılı sonuçlar elde edilmiştir. Bu sistem, enerji kayıplarını önlemek ve yenilenebilir enerji kaynaklarının sürdürülebilirliğini artırmak için kritik bir katkı sunmaktadır.

**Anahtar Kelimeler—** Güneş paneli arızaları, görüntü sınıflandırma, derin öğrenme, toz tespiti, fiziksel hasar, elektriksel sorunlar, Kaggle veri seti, enerji verimliliği, bakım optimizasyonu.

**Abstract—** This project aims to develop an image classification model to detect issues in solar panels, such as dust accumulation, physical damage, and electrical faults. A dataset from Kaggle, consisting of 875 images captured under varying conditions, was utilized. The dataset is categorized as Bird Droppings, Clean, Dusty, Electrical Damage, Physical Damage, and Snow-Covered. The InceptionV3 model achieved a high accuracy of %96.72, providing an efficient solution for enhancing energy efficiency and maintaining the sustainability of renewable energy sources.

**Keywords—** Solar panel faults, image classification, deep learning, dust detection, physical damage, electrical issues, Kaggle dataset, energy efficiency, maintenance optimization.

Güneş panelleri, dünya çapında enerji üretiminde önemli bir yer tutan yenilenebilir enerji kaynağıdır. Ancak çevresel faktörler ve fiziksel etkiler, bu panellerin verimliliğini zamanla düşürmektedir. Toz, kuş dışkısı, kar birikimi, fiziksel çatlaklar ve elektriksel arızalar, verimlilik kaybına neden olan başlıca sorunlardır. Bu projede, güneş panellerindeki bu tür arızaları tespit edebilmek için bir derin öğrenme tabanlı görüntü sınıflandırma sistemi geliştirilmiştir.

Kaggle platformundan elde edilen 875 görüntü, altı kategoriye ayrılmıştır: kuş dışkısı, toz, karla kaplı, temiz, fiziksel hasar ve elektriksel hasar. Bu veri seti, modelin çeşitli koşullarda arıza tespiti yapabilmesini sağlamaktadır. Projeye özel olarak InceptionV3 modeli kullanılmıştır ve model %96.15 doğruluk oranı ile başarılı sonuçlar elde etmiştir.

Modelin konvolüsyonel katmanları, SE blokları ve kalıntı bağlantıları, farklı açılardan ve koşullardan kaynaklanan karmaşıklıkları başarıyla analiz etmektedir. Bu sistem, güneş panellerindeki sorunları gerçek zamanlı olarak tespit ederek enerji kaybını önlemekte ve bakım süreçlerini optimize etmektedir. Sonuç olarak, bu proje yenilenebilir enerji sistemlerinin sürdürülebilirliğine katkı sağlamaktadır.

#### Veri Seti İçeriği:

- Kuş Dışkısı (192 görüntü):** Panellerde kuş dışkısı bulunan görüntüler.
- Temiz (194 görüntü):** Sorunsuz, temiz güneş panellerinin görüntüleri.
- Tozlu (191 görüntü):** Tozla kaplanmış paneller, ışık geçişini engelleyebilir.
- Elektriksel Hasar (104 görüntü):** Elektriksel arızaların olduğu panellerin görüntüleri.
- Fiziksel Hasar (70 görüntü):** Çatlamış veya kırılmış panellerin görüntüleri.
- Karla Kaplı (124 görüntü):** Karla kaplanmış panellerin görüntüleri.

## II. KULLANILAN VERİLER

Bu projede kullanılan veri seti, Kaggle platformundan temin edilen güneş panelleriyle ilgili görüntülerden oluşmaktadır. Veri seti, farklı koşullarda çekilmiş toplam 875 görüntüden oluşmaktadır ve altı ana kategoriye ayrılmaktadır: Kuş Dışkısı (192), Temiz (194), Tozlu (191), Elektriksel Hasar (104), Fiziksel Hasar (70), ve Karla Kaplı (124). Her bir kategori, güneş panellerindeki çeşitli arızaları ve bu arızaların enerji verimliliği üzerindeki etkilerini analiz edebilmek için önemlidir. Görüntüler, modelin doğru sınıflandırma yapabilmesi için kritik veri sağlar.



Şekil 1. Veri setinde bulunan güneş paneli görüntüleri

## III. YÖNTEM

Bu projede, güneş panellerindeki arızaların tespit edilmesi için InceptionV3 tabanlı bir CNN (Convolutional Neural Network) modeli kullanılmaktadır.

### InceptionV3 Modelinin Kullanılması:

InceptionV3, derin öğrenme tabanlı bir Convolutional Neural Network (CNN) modelidir ve görüntü sınıflandırma, nesne algılama gibi birçok bilgisayarla görme uygulamasında etkin bir şekilde kullanılmaktadır. Gelişmiş katman mimarisi ve yenilikçi tasarımı sayesinde, özellikle karmaşık görüntü desenlerini öğrenme ve analiz etme konusunda yüksek bir başarı oranına sahiptir. Bu özellik, güneş panellerindeki hasar türlerini doğru şekilde sınıflandırmada büyük avantaj sağlar.

### InceptionV3 Modelinin Özellikleri:

InceptionV3, Google tarafından geliştirilen ve evrimsel sinir ağlarına (CNN) dayanan bir derin öğrenme modelidir. Görüntü işleme alanında yaygın olarak kullanılan bu model, özellikle çok ölçekli nesneleri tanıma ve karmaşık desenleri analiz etme yeteneğiyle dikkat çeker. Derin mimarisi sayesinde, görüntülerdeki düşük seviyeli özelliklerden (kenar ve köşe gibi) yüksek seviyeli soyut bilgilere kadar geniş bir yelpazede çıkarım yapabilir. Bu özellik, güneş panellerindeki farklı

boyut ve tipteki kusurları (toz, fiziksel hasar, elektriksel hasar gibi) tespit etmekte kritik bir rol oynar. InceptionV3, modüler yapısı ve dikkatle tasarlanmış bloklarıyla parametre verimliliğini artırırken hesaplama yükünü minimize eder. Model, auxiliary classifiers (yardımcı sınıflandırıcılar) gibi ileri teknikler kullanarak öğrenme sürecini daha stabil hale getirir.

### Veri Ön İşleme:

Modelin daha hızlı ve verimli çalışabilmesi için veri ön işleme aşamasında aşağıdaki işlemler gerçekleştirilmiştir:

1. **Görüntü Boyutlandırma:** Tüm görüntüler, modelle uyumlu olması için 224x224 piksel boyutuna yeniden ölçeklendirilmiştir. Bu, hem modelin girdilerini standart hale getirir hem de hesaplama maliyetini düşürür.
2. **Normalize İşlemi:** Görüntülerdeki her piksel değeri, 0 ile 1 arasında normalize edilmiştir. Bu işlem, ağın daha kararlı bir şekilde çalışmasını sağlayarak öğrenme sürecinde ağırlıkların daha hızlı yakınsamasına yardımcı olmuştur.

Ayrıca, modelin genelleme yeteneğini artırmak için veri artırma (data augmentation) teknikleri uygulanmıştır. Bu teknikler şunları içerir:


- Rastgele döndürme,
- Parlaklık ayarlamaları,
- Yatay ve dikey çevirme,
- Hafif gürültü ekleme.

### Neden InceptionV3 Kullanıldı?

InceptionV3, derin öğrenme tabanlı bir CNN modeli olarak karmaşık görüntü verilerini işlemek için etkili bir mimariye sahiptir. Model, aşağıdaki nedenlerle tercih edilmiştir:

1. **Verimlilik:** Düşük parametre sayısı ve optimize edilmiş yapı taşları sayesinde hesaplama maliyeti düşüktür. Bu, modelin büyük veri setleriyle bile hızlı bir şekilde eğitilmesini sağlar.
2. **Genelleme Kapasitesi:** Çok ölçekli filtreler ve farklı konvolüsyonel çekirdekler kullanarak görüntüdeki çeşitli desenleri etkili bir şekilde tanıır.
3. **Yüksek Doğruluk:** İnce ayarlı yapısı sayesinde sınıflandırma görevlerinde yüksek performans sunar.

Esneklik: Güneş panellerindeki kar, toz, fiziksel hasar gibi farklı türdeki arızaları başarılı bir şekilde ayırt edebilme yeteneğine sahiptir.



Şekil 2. InceptionV3 modelinin mimarisi

## Model Eğitimi:

Modelin eğitimi sırasında veri seti, %80 eğitim ve %20 test olarak ayrılmıştır. Eğitim verileri modelin öğrenmesinde, test verileri ise doğruluğunu değerlendirmede kullanılmıştır. Optimizasyon sürecinde Adam optimizasyon algoritması tercih edilmiştir; bu algoritma, öğrenme oranını dinamik bir şekilde ayarlayarak daha hızlı ve etkili bir öğrenme süreci sağlamıştır. Çapraz Entropi Kaybı (Cross-Entropy Loss), sınıflandırma hatalarını ölçmek ve modelin performansını optimize etmek için kullanılmıştır. Eğitim sürecinde, doğruluk (accuracy) ve kayıp (loss) değerleri sürekli izlenmiş, modelin performansı arttıkça ince ayarlamalar yapılmıştır.

## IV. DRONE TEKNOLOJİSİ İLE UYGULAMA

Geliştirilen sistemin drone teknolojisi ile entegrasyonu, arıza tespit sürecinde önemli avantajlar sağlamaktadır. Güneş panelleri genellikle geniş arazilerde, çatı sistemlerinde veya zorlu coğrafi koşullarda kurulu olduğundan, drone'lar bu alanlara kolaylıkla erişim sağlayarak görüntü toplama sürecini hızlandırır ve insan müdahalesine olan ihtiyacı azaltır. Özellikle büyük ölçekli güneş enerjisi santrallerinde drone'lar geniş alanları kısa sürede tarayarak yüksek çözünürlüklü görüntüler elde etmeyi mümkün kılar. Bu durum, bakım ve izleme süreçlerinin optimize edilmesinde önemli bir rol oynar. Bunun yanı sıra, canlı görüntü aktarımı ve analiz yetenekleri sayesinde drone'lar arızaların gerçek zamanlı tespitine olanak tanır ve böylece enerji kayıplarını önlemek için hızlı müdahale imkanı sunar.

## V. SONUÇ VE TARTIŞMA

Bu çalışmada, güneş panellerindeki farklı arıza türlerini tespit etmek amacıyla derin öğrenme tabanlı bir görüntü sınıflandırma sistemi geliştirilmiş ve %96.72 doğruluk oranıyla altı kategoride başarılı bir sınıflandırma gerçekleştirilmiştir. Geliştirilen sistem, enerji verimliliğini artırma ve yenilenebilir enerji kaynaklarının sürdürülebilirliğini destekleme açısından önemli bir potansiyele sahiptir. Özellikle drone teknolojisi entegrasyonu, sistemin daha geniş alanlarda etkili bir şekilde uygulanabilirliğini artırmaktadır. Bununla birlikte, gelecekteki çalışmalar, IoT cihazları ile veri senkronizasyonu, drone'ların yapay zeka algoritmalarıyla donatılması ve gerçek zamanlı veri analitiği gibi konulara odaklanabilir. Bu tür geliştirmeler, sistemin doğruluğunu ve verimliliğini daha da artırarak yenilenebilir enerji kaynaklarının yönetiminde devrim yaratabilir. Bu bağlamda, çalışma yalnızca bilimsel değil, aynı zamanda çevresel ve ekonomik açıdan da önemli katkılar sağlamaktadır.

## REFERENCES

- [1] Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2818-2826).
- [2] CHOLLET, Francois. The limitations of deep learning. *Deep learning with Python*, 2017.
- [3] LERMI, Sebahattin Yiğit; ONUR, Tuğba Özge. Güneş Paneli Kusurlarının Derin Öğrenme Tabanlı Sınıflandırılması. *International Journal of Advances in Engineering and Pure Sciences*, 2024, 36.2: 140-149.
- [4] Onim, Md Saif Hassan, et al. "SolNet: a convolutional neural network for detecting dust on solar panels." *Energies* 16.1 (2022): 155.